

2014.3.19

## 第九讲 线性回归模型（2）

参数的含义及最小二乘估计

回顾一般线性模型的两表示：

模型表示 1:

$y$ : 响应变量,  $\mathbf{x}$ : 自变量(向量)。线性回归模型假设:

(i) 线性回归函数:  $E(y | \mathbf{x}) = a + \mathbf{b}'\mathbf{x}$ ,

(ii) 方差常数/齐性:  $\text{var}(y | \mathbf{x}) = \sigma^2$ .

其中  $a, \mathbf{b}, \sigma^2$  是未知参数。

模型表示 2:

$$y = a + \mathbf{b}'\mathbf{x} + \varepsilon,$$

其中

(1)  $E(\varepsilon) = 0$

(2)  $\text{var}(\varepsilon) = \sigma^2$  (方差齐性, Homoscedasticity)

(3)  $\varepsilon$  与  $\mathbf{x}$  独立 (外生性, Exogeneity)

例2(单因素方差分析模型).  $n$  个个体被随机地分配于  $K$  组分别接受某种处理(*treatment*), 并测量某指标。假设第  $k$  组有  $n_k$  个个体, 指标测量为  $y_{k1}, \dots, y_{kn_k} \text{ iid } \sim N(\mu_k, \sigma^2), k = 1, \dots, K$

记  $\varepsilon_{kj} = y_{kj} - \mu_k, j = 1, \dots, n_k \text{ iid } \sim N(0, \sigma^2), k = 1, \dots, K$ , 即

$$y_{kj} = \mu_k + \varepsilon_{kj},$$

模型可表示为:  $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, E\boldsymbol{\varepsilon} = 0, \text{var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_n$ , 其中

$$\mathbf{Y} = \begin{pmatrix} y_{11} \\ \vdots \\ y_{1n_1} \\ \vdots \\ y_{K1} \\ \vdots \\ y_{Kn_K} \end{pmatrix}, \mathbf{X} = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ \vdots & \vdots & \cdots & \vdots \\ 1 & 0 & \cdots & 0 \\ \vdots & \vdots & \cdots & \vdots \\ 0 & 0 & \cdots & 1 \\ \vdots & \vdots & \cdots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix}, \boldsymbol{\beta} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_K \end{pmatrix}, \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_{11} \\ \vdots \\ \varepsilon_{1n_1} \\ \vdots \\ \varepsilon_{K1} \\ \vdots \\ \varepsilon_{Kn_K} \end{pmatrix}$$

为了检验  $K$  个均值相同, 通常重新参数化, 比如令

$$\beta_1 = \mu_1, \beta_2 = \mu_2 - \mu_1, \dots, \beta_K = \mu_K - \mu_1,$$

对于上述新参数  $\tilde{\boldsymbol{\beta}} = (\beta_1, \dots, \beta_K)'$ , 写出模型

$$\mathbf{Y} = \mathbf{X}\tilde{\boldsymbol{\beta}} + \boldsymbol{\varepsilon}, E\boldsymbol{\varepsilon} = 0, \text{var}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_n$$

中的设计阵  $\mathbf{X}$

## 参数含义 - 以简单线性回归模型为例

简单线性模型:  $y = a + bx + \varepsilon$

(1)  $E(\varepsilon) = 0$ , (2)  $\text{var}(\varepsilon) = \sigma^2$  (3)  $\varepsilon$ 与 $x$ 不相关/独立

### ■ 参数的含义

命题: 记  $\mu_x = E(x)$ ,  $\mu_y = E(y)$ ,  $\sigma_x = \sqrt{\text{var}(x)}$ ,  $\sigma_y = \sqrt{\text{var}(y)}$ ,  $\rho = \rho_{xy}$ , 则

(1)  $b = \rho \frac{\sigma_y}{\sigma_x} \propto \rho$ , 所以  $b = 0 \Leftrightarrow \rho = 0$

(2)  $a = \mu_y - b\mu_x$ ,

(3)  $\sigma^2 = (1 - \rho^2)\sigma_y^2$

证明: (1) 由  $\varepsilon = y - a - bx \perp x \Rightarrow 0 = \text{cov}(\varepsilon, x) = \text{cov}(y - a - bx, x)$   
 $= \text{cov}(y, x) - b \text{var}(x) \Rightarrow b = \frac{\text{cov}(y, x)}{\text{var}(x)} = \rho \sqrt{\frac{\text{var}(y)}{\text{var}(x)}} = \rho \frac{\sigma_y}{\sigma_x}$

(2) 由  $\mu_y = E(y) = E(a + bx + \varepsilon) = a + b\mu_x \Rightarrow a = \mu_y - b\mu_x$

(3) 由  $y = a + bx + \varepsilon$ , 以及  $\varepsilon$ 与 $x$ 独立, 有如下方差分解  
 $\text{var}(y) = \text{var}(a + bx) + \text{var}(\varepsilon)$ , 即  $\sigma_y^2 = b^2 \sigma_x^2 + \sigma^2$

所以  $\sigma^2 = \sigma_y^2 - b^2 \sigma_x^2 = \sigma_y^2 - \left( \frac{\rho^2 \sigma_y^2}{\sigma_x^2} \right) \sigma_x^2 = (1 - \rho^2) \sigma_y^2$

注: 由 (3) 我们得到  $\rho^2 = \frac{\sigma_y^2 - \sigma^2}{\sigma_y^2} = \frac{\text{var}(a + bx)}{\text{var}(y)}$

所以  $x, y$  相关系数的平方 = 回归直线所能解释的  $y$  的方差的百分比


### ■ 回归效应

假设  $(x, y)$  服从二元正态分布, 对给定的  $x$ ,  $y$  服从图中所示的正态分布

该正态分布的中心,  $E(y|x)$ , 在对称轴(虚线)之下

$x$  变化时,  $f(x) = E(y|x)$  形成回归直线(红), 称为回归函数。

相比于虚线, 回归直线在两端有向中心回归的趋势。



虚线称为SD线:  $x$  偏离其中心1个SD,  $y$  也偏离其中心一个SD

假设  $(x, y)$  服从如下简单线性模型

$$E(y|x) = a + bx, \text{var}(y|x) = \sigma^2$$

如果已知  $x$  超过其均值  $k$  个单位 ( $x = \mu_x + k\sigma_x$ ),

你是否预期  $y$  超过其均值  $k$  个单位,  $E(y|x = \mu_x + k\sigma_x) = \mu_y + k\sigma_y$ ?

当  $x = \mu_x + k\sigma_x$  时:  $E(y|x) = \mu_y + bk\sigma_x = \mu_y + k\rho_{xy}\sigma_y < \mu_y + k\sigma_y$

同样当  $x = \mu_x - k\sigma_x$ ,  $E(y|x) = \mu_y - k\rho_{xy}\sigma_y > \mu_y - k\sigma_y$ .

所以回归直线不是虚线(SD线), 而是实线。



例. 课外培训教育是否能提高儿童的IQ? 考察入学前IQ值低于平均水平的那些儿童, 发现经过一段时间的培训, 其IQ值平均提高了5分。以此现象来宣传培训效果是否可信?

实际上, 学前比平均分高的儿童在入学后的IQ可能平均降低了5分! 此现象可能只是回归效应, 并不一定能说明真的有效。

如果入学前后平均IQ值相同, 标准差也相同, 那么上述现象是正常的回归效应。

又比如减肥药的宣传、高尔顿的父子身高问题等

## 简单线性回归模型的最小二乘法


1. 最小二乘估计
2. 最小二乘估计的性质
3. 正态模型下的统计推断

### 1. 最小二乘估计 (Least Squares, LS)

#### ■ 方法

假设 $(x_i, y_i), i = 1, 2, \dots, n$ . iid 满足线性模型:

$$y_i = a + bx_i + \varepsilon_i, \quad \varepsilon_i \text{ iid } \sim (0, \sigma^2), \varepsilon_i \text{ 与 } x_i \text{ 独立.}$$



最小二乘法极小化误差平方和:

$$\min \sum_{i=1}^n \varepsilon_i^2 = \min \sum_{i=1}^n (y_i - a - bx_i)^2$$

求导得到正则方程:

$$\begin{cases} \sum (y_i - a - bx_i) = 0 \\ \sum x_i (y_i - a - bx_i) = 0 \end{cases}$$

注: 正则方程可理解为模型条件的“矩估计方法”实现:

$$\sum (y_i - a - bx_i) = \sum \varepsilon_i = 0 \quad \leftarrow E(\varepsilon) = 0$$

$$\sum x_i (y_i - a - bx_i) = \sum x_i \varepsilon_i = 0 \quad \leftarrow x \text{ 与 } \varepsilon \text{ 独立 / 不相关}$$

得到LS估计: 
$$\begin{cases} \hat{b} = s_{xy} / s_{xx} \\ \hat{a} = \bar{y} - \hat{b}\bar{x} \end{cases}$$

$$\begin{aligned} s_{xx} &= \sum (x_i - \bar{x})^2, \\ s_{xy} &= \sum (x_i - \bar{x})(y_i - \bar{y}) \end{aligned}$$

改写 $\hat{b}$ :

$$\begin{aligned} \hat{b} &= \frac{s_{xy}}{s_{xx}} = \frac{s_{xy}}{\sqrt{s_{xx}s_{yy}}} \times \sqrt{\frac{s_{yy}}{s_{xx}}} = r_{xy} \times \frac{s_y}{s_x}, \\ \hat{a} &= \bar{y} - \hat{b}\bar{x} \end{aligned}$$

样本标准差


$$\begin{aligned} s_x &= \sqrt{\sum (x_i - \bar{x})^2 / (n-1)}, \\ s_y &= \sqrt{\sum (y_i - \bar{y})^2 / (n-1)} \end{aligned}$$

对比参数的表示:

$$(1) b = \rho \frac{\sigma_y}{\sigma_x}; (2) a = \mu_y - b\mu_x,$$

## ■ 拟合值与残差

拟合直线:  $y = \hat{a} + \hat{b}x$  或  $y - \bar{y} = r \frac{s_y}{s_x} (x - \bar{x})$



• 拟合值(fitted value):  $\hat{y}_i = \hat{a} + \hat{b}x_i$ ,

• 残差(residual):  $e_i = y_i - \hat{y}_i = y_i - \hat{a} - \hat{b}x_i$ ,

• 残差平方和RSS (Residual Sum of Squares):

$$RSS = \sum e_i^2 = \sum (y_i - \hat{y}_i)^2 = \sum (y_i - \hat{a} - \hat{b}x_i)^2$$

即最小的误差平方和

•  $RSS = s_{yy} - s_{xy}^2 / s_{xx} = s_{yy}(1 - r^2)$

$$\begin{aligned} \text{验证: } RSS &= \sum (y_i - \hat{a} - \hat{b}x_i)^2 = \sum (y_i - \bar{y} + \hat{b}\bar{x} - \hat{b}x_i)^2 \\ &= s_{yy} - 2\hat{b}s_{xy} + \hat{b}^2s_{xx} = s_{yy} - s_{xy}^2 / s_{xx} \end{aligned}$$

性质:  $\sum e_i = 0, \sum e_i x_i = 0, \sum e_i \hat{y}_i = 0,$

此即正则方程

$$\begin{cases} 0 = \sum (y_i - \hat{a} - \hat{b}x_i) = \sum e_i \\ 0 = \sum x_i (y_i - \hat{a} - \hat{b}x_i) = \sum x_i e_i \end{cases}$$

## ■ 误差方差估计

因为  $\sigma^2 = \text{var}(\varepsilon_i) = E(\varepsilon_i^2)$ ,  $\varepsilon_i = y_i - a - bx_i$

而  $e_i = y_i - \hat{a} - \hat{b}x_i$  可看作是  $\varepsilon_i$  的“估计”（预测）

$\sigma^2$  的“LS”估计取为：

$$\hat{\sigma}^2 = \frac{1}{n-2} RSS = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{a} - \hat{b}x_i)^2$$

虽然它不是由最小二乘法（极小化误差平方和）直接得到的，但通常也称它为LS估计。

## ■ 复相关系数平方

注意到  $\sum \hat{y}_i = \sum y_i = n\bar{y}$ , 我们有平方和分解：

$$s_{yy} = \sum (y_i - \bar{y})^2 = \sum (y_i - \hat{y}_i + \hat{y}_i - \bar{y})^2 = \sum (\hat{y}_i - \bar{y})^2 + \sum (y_i - \hat{y}_i)^2$$

即总平方和  $s_{yy} = s_{\hat{y}\hat{y}} + RSS$  = 回归平方和 + 残差平方和

定义：对于一般(多重)线性回归, 复相关系数平方  $R^2$  定义为回归函数(或自变量)所能解释的响应变量方差的百分比：

$$R^2 = \frac{s_{\hat{y}\hat{y}}}{s_{yy}} = \frac{\sum (\hat{y}_i - \bar{y})^2}{\sum (y_i - \bar{y})^2}$$

对于简单回归： $s_{\hat{y}\hat{y}} = \sum (\hat{a} + \hat{b}x_i - (\hat{a} + \hat{b}\bar{x}))^2 = \hat{b}^2 s_{xx} = s_{xy}^2 / s_{xx}$

所以  $R^2 = s_{xy}^2 / s_{xx} s_{yy} = r^2$

总结如下：

$$y = a + bx + \varepsilon, \quad \varepsilon \sim (0, \sigma^2), \varepsilon \perp x$$

参数

$$(1) b = \frac{\text{cov}(x, y)}{\text{var}(x)} = \rho \frac{\sigma_y}{\sigma_x}$$

$$(2) a = \mu_y - b\mu_x,$$

$$(3) \sigma^2 = (1 - \rho^2) \sigma_y^2$$

LS估计

$$(1) \hat{b} = \frac{s_{xy}}{s_{xx}} = r \frac{s_y}{s_x}$$

$$(2) \hat{a} = \bar{y} - \hat{b}\bar{x}$$

$$(3) \hat{\sigma}^2 = (1 - r^2) s_y^2 \times \frac{n-1}{n-2} \approx (1 - r^2) s_y^2$$

## 2. 最小二乘估计的性质

性质1 (无偏性).  $E(\hat{b}) = b, E(\hat{a}) = a, E(\hat{\sigma}^2 | \mathbf{x}) = \sigma^2$

证明:  $\hat{b} = s_{xy} / s_{xx}$

$$(1) E(\hat{b} | \mathbf{x}) = E\left(\frac{\sum (x_i - \bar{x}) y_i}{\sum (x_i - \bar{x})^2} \middle| \mathbf{x}\right) = \frac{\sum (x_i - \bar{x}) E(y_i | x_i)}{\sum (x_i - \bar{x})^2}$$

$$= \frac{\sum (x_i - \bar{x})(a + bx_i + E(\varepsilon_i | x_i))}{\sum (x_i - \bar{x})^2} = \frac{\sum (x_i - \bar{x})(bx_i)}{\sum (x_i - \bar{x})^2} = b$$

$\Rightarrow E(\hat{b}) = b$

由  $\varepsilon$  与  $x$  独立,  $E(\varepsilon_i | x_i) = E(\varepsilon_i) = 0$

(2) 另外,  $E(\hat{a} | \mathbf{x}) = E(\bar{y} - \hat{b}\bar{x} | \mathbf{x}) = a + b\bar{x} - E(\hat{b} | \mathbf{x})\bar{x} = a$

引入向量记号重述上述证明:

令  $\mathbf{x} = (x_1, \dots, x_n)'$ ,  $\mathbf{y} = (y_1, \dots, y_n)'$ ,  $\mathbf{1} = (1, \dots, 1)'$

则  $\hat{b} = s_{xy} / s_{xx} = \frac{1}{s_{xx}} (\mathbf{x} - \bar{\mathbf{x}})' \mathbf{y}$

$$\begin{aligned} E(\hat{b} | \mathbf{x}) &= \frac{(\mathbf{x} - \bar{\mathbf{x}})'}{s_{xx}} E(\mathbf{y} | \mathbf{x}) = \frac{(\mathbf{x} - \bar{\mathbf{x}})'}{s_{xx}} E(\mathbf{1}a + \mathbf{x}b + \boldsymbol{\varepsilon} | \mathbf{x}) \\ &= \frac{(\mathbf{x} - \bar{\mathbf{x}})' \mathbf{1}a}{s_{xx}} + \frac{(\mathbf{x} - \bar{\mathbf{x}})' \mathbf{x}b}{s_{xx}} + \frac{(\mathbf{x} - \bar{\mathbf{x}})' E(\boldsymbol{\varepsilon} | \mathbf{x})}{s_{xx}} \\ &= 0 + b + \frac{(\mathbf{x} - \bar{\mathbf{x}})'}{s_{xx}} E(\boldsymbol{\varepsilon}) = b \end{aligned}$$

注: 无偏性需要条件  $E(\boldsymbol{\varepsilon}) = 0$  以及  $\boldsymbol{\varepsilon}$  与  $\mathbf{x}$  的独立性, 但不需要方差齐性。

(3)  $\hat{y}_i = \hat{a} + \hat{b}x_i$ , 向量形式:  $\hat{\mathbf{y}} = \mathbf{1}\hat{a} + \mathbf{x}\hat{b}$

而  $\hat{b} = s_{xy} / s_{xx} = \frac{(\mathbf{x} - \bar{\mathbf{x}})' \mathbf{y}}{(\mathbf{x} - \bar{\mathbf{x}})' (\mathbf{x} - \bar{\mathbf{x}})}$ ,

将拟合值向量写成  $\mathbf{y}$  的线性变换形式:

$$\begin{aligned} \hat{\mathbf{y}} &= \mathbf{1}\hat{a} + \mathbf{x}\hat{b} = \mathbf{1}(\bar{y} - \bar{b}\bar{x}) + \mathbf{x}\hat{b} = \mathbf{1}\bar{y} + (\mathbf{x} - \bar{x}\mathbf{1})\hat{b} \\ &= \frac{\mathbf{1}\mathbf{1}'}{n} \mathbf{y} + (\mathbf{x} - \bar{x}\mathbf{1}) \frac{(\mathbf{x} - \bar{\mathbf{x}})' \mathbf{y}}{(\mathbf{x} - \bar{\mathbf{x}})' (\mathbf{x} - \bar{\mathbf{x}})} \\ &= \left( \frac{\mathbf{1}\mathbf{1}'}{n} + \frac{(\mathbf{x} - \bar{x}\mathbf{1})(\mathbf{x} - \bar{\mathbf{x}})'}{(\mathbf{x} - \bar{\mathbf{x}})' (\mathbf{x} - \bar{\mathbf{x}})} \right) \mathbf{y} \end{aligned}$$

$$\text{残差向量 } \mathbf{e} = \mathbf{y} - \hat{\mathbf{y}} = \left( I_n - \frac{\mathbf{1}\mathbf{1}'}{n} - \frac{(\mathbf{x} - \bar{x}\mathbf{1})(\mathbf{x} - \bar{\mathbf{x}})'}{(\mathbf{x} - \bar{\mathbf{x}})' (\mathbf{x} - \bar{\mathbf{x}})} \right) \mathbf{y} \stackrel{\text{记为}}{=} C\mathbf{y}$$

容易验证  $C$  是对称幂等矩阵, 所以  $(I - C)$  也是, 而且:

$$\text{tr}(C) = n - 2, \quad C\mathbf{1} = 0, \quad C\mathbf{x} = 0$$

则给定  $\mathbf{x}$  的条件下,

$$\begin{aligned} E(\text{RSS} | \mathbf{x}) &= E(\mathbf{e}'\mathbf{e} | \mathbf{x}) = E(\mathbf{y}'C\mathbf{y} | \mathbf{x}) \\ &= (\mathbf{1}a + \mathbf{x}b)' C (\mathbf{1}a + \mathbf{x}b) + \text{tr}(C) \sigma^2 \\ &= (n - 2) \sigma^2 \end{aligned}$$

$$\text{所以 } E(\hat{\sigma}^2 | \mathbf{x}) = E(\text{RSS} / (n - 2) | \mathbf{x}) = \sigma^2.$$

注: 事实上,  $P = I - C$  是  $L(\mathbf{1}, \mathbf{x})$  对应的投影矩阵。

$\hat{\mathbf{y}} = P\mathbf{y}$  是  $\mathbf{y}$  在  $L(\mathbf{1}, \mathbf{x})$  上的投影。