

## 第十四讲. 最小二乘

1

模型蕴含了如下事实:

- (1) 均值线性: 各个自变量对响应变量的效应是可加的, 且回归系数不受其它自变量取值的影响, (否则考虑高阶模型, 引入交互作用).
- (2) 误差均值为0: 可识别, 否则截距项无法估计;
- (3) 方差齐性: 数据的一致性 (不是必须的假设)
- (4) 误差项与自变量独立: 保证回归系数估计的无偏性

3

## 1. 多重线性回归模型

(总体)模型:

$$y = \mathbf{x}'\boldsymbol{\beta} + \varepsilon = \beta_1 + \beta_2 x_2 + \dots + \beta_p x_p + \varepsilon, \text{ 其中}$$

$$(1) \varepsilon \sim (0, \sigma^2),$$

(2)  $\varepsilon$ 与 $\mathbf{x}$ 独立。

有时也采用如下模型假设

$y$ 是响应变量,  $\mathbf{x} = (1, x_2, \dots, x_p)'$ 是 $p \times 1$ 向量(自变量),  
多重线性模型(总体模型)

$$\text{均值线性: } E(y | \mathbf{x}) = \mathbf{x}'\boldsymbol{\beta} = \beta_1 + \beta_2 x_2 + \dots + \beta_p x_p,$$

$$\text{方差齐性: } \text{var}(y | \mathbf{x}) = \sigma^2$$

2

## 回归系数正比于偏相关系数

以 $\mathbf{x}_{(-k)}$ 表示 $\mathbf{x}$ 向量中除了 $x_k$ 之外其他分量组成的向量,  
 $\boldsymbol{\beta}_{(-k)}$ 表示 $\boldsymbol{\beta}$ 向量中除了 $\beta_k$ 之外其他分量组成的向量,

$$\text{令 } x_k^\perp = x_k - \boldsymbol{\Sigma}_{k(-k)} \boldsymbol{\Sigma}_{(-k)(-k)}^{-1} x_{(-k)}, \text{ 改写}$$

$$y = \beta_k x_k + \boldsymbol{\beta}_{(-k)}' \mathbf{x}_{(-k)} + \varepsilon = \beta_k x_k^\perp + \tilde{\boldsymbol{\beta}}_{(-k)}' \mathbf{x}_{(-k)} + \varepsilon$$

$$\text{其中 } \tilde{\boldsymbol{\beta}}_{(-k)} = \boldsymbol{\beta}_{(-k)} + \beta_k \boldsymbol{\Sigma}_{k(-k)} \boldsymbol{\Sigma}_{(-k)(-k)}^{-1}$$

$$\text{所以 } \text{cov}(y, x_k^\perp) = \text{cov}(\beta_k x_k^\perp + \tilde{\boldsymbol{\beta}}_{(-k)}' \mathbf{x}_{(-k)} + \varepsilon, x_k^\perp) = \beta_k \text{var}(x_k^\perp)$$

$$\text{所以 } \beta_k = \frac{\text{cov}(y, x_k^\perp)}{\text{var}(x_k^\perp)} = \frac{\text{cov}(y^\perp, x_k^\perp)}{\text{var}(x_k^\perp)} = \rho_{y^\perp x_k^\perp} \sqrt{\frac{\text{var}(y^\perp)}{\text{var}(x_k^\perp)}} \propto \rho_{y^\perp x_k^\perp}$$

4

## 模型的数据形式

数据:  $(y_i, \tilde{\mathbf{x}}_i)$ ,  $i=1,2,\dots,n$  独立, 其中  $p \times 1$  向量  $\tilde{\mathbf{x}}_i$  为自变量的第  $i$  个观察值,  $y_i$  为响应变量,  $i=1,2,\dots,n$ .

假设  $(y_i, \tilde{\mathbf{x}}_i)$ ,  $i=1,2,\dots,n$ , 独立, 满足多重线性回归模型:

$$y = \mathbf{x}'\boldsymbol{\beta} + \varepsilon, \quad \varepsilon \sim (0, \sigma^2), \quad \varepsilon \text{ 与 } \mathbf{x} \text{ 独立}$$

其中  $\boldsymbol{\beta}$  为  $p \times 1$  回归系数列向量。即

线性回归模型:

$$y_i = \tilde{\mathbf{x}}_i' \boldsymbol{\beta} + \varepsilon_i, i=1,2,\dots,n$$

其中  $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$  iid  $\sim (0, \sigma^2)$ , 且  $\varepsilon_i$  与  $\tilde{\mathbf{x}}_i$  独立。

5

记

$$\mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{pmatrix}, \quad X = \begin{pmatrix} \tilde{\mathbf{x}}_1' \\ \tilde{\mathbf{x}}_2' \\ \dots \\ \tilde{\mathbf{x}}_n' \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \dots \\ \beta_p \end{pmatrix}, \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \dots \\ \varepsilon_n \end{pmatrix},$$

其中  $X$  称为设计阵(第  $i$  行为  $\tilde{\mathbf{x}}_i'$ )。

线性回归模型(矩阵-向量形式):

$$\mathbf{Y}_{n \times 1} = X_{n \times p} \boldsymbol{\beta}_{p \times 1} + \boldsymbol{\varepsilon}_{n \times 1}, \quad \boldsymbol{\varepsilon} \sim (\mathbf{0}, \sigma^2 I_n), \quad \boldsymbol{\varepsilon} \text{ 与 } X \text{ 独立}。$$

或有时用前两阶矩定义 模型:

$$(a) \quad E(\mathbf{Y}|X) = X\boldsymbol{\beta},$$

$$(b) \quad \text{var}(\mathbf{Y}|X) = \sigma^2 I_n$$

6

## 2. 最小二乘

最小二乘法:

假设  $X$  列满秩 (必要条件:  $n \geq p$ ), 最小二乘法 (LS):

$$\min_{\boldsymbol{\beta}} \sum (y_i - \tilde{\mathbf{x}}_i' \boldsymbol{\beta})^2 = \min_{\boldsymbol{\beta}} \|\mathbf{Y} - X\boldsymbol{\beta}\|^2$$

求导(见下页)得正则方程:

$$X'(\mathbf{Y} - X\boldsymbol{\beta}) = 0$$

$$\Rightarrow X'\mathbf{Y} = X'X\boldsymbol{\beta}$$

$$\Rightarrow \text{LS 估计: } \hat{\boldsymbol{\beta}} = (X'X)^{-1} X'\mathbf{Y}$$

$$\text{且 } \text{var}(\hat{\boldsymbol{\beta}} | X) = \sigma^2 (X'X)^{-1}$$

矩方法:  $\mathbf{0} = X'\boldsymbol{\varepsilon} = X'(\mathbf{Y} - X\boldsymbol{\beta})$

由  $\boldsymbol{\varepsilon}$  与  $X$  的各列独立

pre-conditioning:

方程  $\mathbf{Y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$  两边同乘  $X'$

7

关于矩阵/向量求导:

设  $y = f(X)$  为一矩阵函数,

其中  $X = (x_{ij})$ ,  $1 \leq i \leq n$ ,  $1 \leq j \leq m$  为  $n \times m$  矩阵,

$$\text{定义 } \frac{\partial y}{\partial X} = \left( \frac{\partial y}{\partial x_{ij}}, 1 \leq i \leq n, 1 \leq j \leq m \right)$$

特别地

$$(1) \quad \text{若 } \mathbf{a}, \mathbf{x} \in \mathbb{R}^n, y = \mathbf{a}'\mathbf{x}, \text{ 则 } \frac{\partial (\mathbf{a}'\mathbf{x})}{\partial \mathbf{x}} = \mathbf{a}$$

$$(2) \quad \text{若 } A \text{ 为 } n \times n \text{ 对称矩阵}, \mathbf{x} \in \mathbb{R}^n, \text{ 则 } \frac{\partial (\mathbf{x}' A \mathbf{x})}{\partial \mathbf{x}} = 2A\mathbf{x}$$

$$LS: \|\mathbf{Y} - X\boldsymbol{\beta}\|^2 = \mathbf{Y}'\mathbf{Y} - 2\mathbf{Y}'X\boldsymbol{\beta} + \boldsymbol{\beta}'X'X\boldsymbol{\beta}$$

$$\text{则 } \frac{\partial (\|\mathbf{Y} - X\boldsymbol{\beta}\|^2)}{\partial \boldsymbol{\beta}} = -2(\mathbf{Y}'X)' + 2X'X\boldsymbol{\beta} = -2X'(\mathbf{Y} - X\boldsymbol{\beta})$$

8

## 部分回归系数的LS估计:

命题1: 划分  $X = (X_1, X_2)$ ,  $\beta = \begin{pmatrix} \beta_{(1)} \\ \beta_{(2)} \end{pmatrix} \begin{matrix} (p-q) \times 1 \\ q \times 1 \end{matrix}$ , 设  $\mathbf{1}$  在  $X_1$  中。

$$Y = X\beta + \varepsilon = X_1\beta_{(1)} + X_2\beta_{(2)} + \varepsilon,$$

令  $X_2^\perp = X_2 - P_{X_1}X_2$ , 则  $\beta_{(2)}$  的LS估计为  $\hat{\beta}_{(2)} = (X_2^{\perp'}X_2^\perp)^{-1}X_2^{\perp'}Y$

且  $\text{var}(\hat{\beta}_{(2)} | X) = \sigma^2(X_2^{\perp'}X_2^\perp)^{-1}$

命题2. 特别地, 令  $X_{(-k)}$  为  $X$  除了第  $k$  列  $\mathbf{x}_k$  之外的其它列组成的矩阵,

$X = (X_{(-k)}, \mathbf{x}_k)$ , 则第  $k$  个回归系数  $\beta_k$  的估计:

$$\hat{\beta}_k = (\mathbf{x}_k^\perp' \mathbf{x}_k^\perp)^{-1} \mathbf{x}_k^\perp' Y = s_{x_k^\perp y} / s_{x_k^\perp x_k^\perp}, \quad \text{且 } \text{var}(\hat{\beta}_k | X) = \sigma^2 (\mathbf{x}_k^\perp' \mathbf{x}_k^\perp)^{-1}$$

其中  $\mathbf{x}_k^\perp = \mathbf{x}_k - P_{X_{(-k)}} \mathbf{x}_k$

$$\text{若 } \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} > 0, \text{ 则 } \Sigma^{-1} = \begin{pmatrix} \Sigma_{11}^{-1} & -\Sigma_{11}^{-1}\Sigma_{12}\Sigma_{22}^{-1} \\ -\Sigma_{22}^{-1}\Sigma_{21}\Sigma_{11}^{-1} & \Sigma_{22}^{-1} \end{pmatrix}$$

证明: 由于  $X = (X_1, X_2)$ , 由分块矩阵求逆公式知

$$\begin{aligned} (X'X)^{-1} &= \begin{pmatrix} X_1'X_1 & X_1'X_2 \\ X_2'X_1 & X_2'X_2 \end{pmatrix}^{-1} = \begin{pmatrix} * & * \\ * & (X_2'X_2 - X_2'X_1(X_1'X_1)^{-1}X_1'X_2)^{-1} \end{pmatrix} \\ &= \begin{pmatrix} * & * \\ * & (X_2^{\perp'}X_2^\perp)^{-1} \end{pmatrix} = \begin{pmatrix} * & * \\ - (X_2^{\perp'}X_2^\perp)^{-1}X_2^{\perp'}X_1(X_1'X_1)^{-1} & (X_2^{\perp'}X_2^\perp)^{-1} \end{pmatrix} \end{aligned}$$

$$\text{另外 } X'Y = \begin{pmatrix} X_1'Y \\ X_2'Y \end{pmatrix}, \text{ 所以 } \hat{\beta} = \begin{pmatrix} \hat{\beta}_{(1)} \\ \hat{\beta}_{(2)} \end{pmatrix} = \begin{pmatrix} X_1'X_1 & X_1'X_2 \\ X_2'X_1 & X_2'X_2 \end{pmatrix}^{-1} \begin{pmatrix} X_1'Y \\ X_2'Y \end{pmatrix}$$

$$\begin{aligned} \text{所以 } \hat{\beta}_{(2)} &= - (X_2^{\perp'}X_2^\perp)^{-1} X_2^{\perp'}X_1(X_1'X_1)^{-1} X_1'Y + (X_2^{\perp'}X_2^\perp)^{-1} X_2^{\perp'}Y \\ &= (X_2^{\perp'}X_2^\perp)^{-1} [X_2^{\perp'} - X_2^{\perp'}X_1(X_1'X_1)^{-1}X_1']Y = (X_2^{\perp'}X_2^\perp)^{-1} X_2^{\perp'}Y \end{aligned}$$