

第十五讲. 最小二乘与投影

1

最小二乘(续): 拟合值与残差

模型:  $\mathbf{Y}_{n \times 1} = \mathbf{X}_{n \times p} \boldsymbol{\beta}_{p \times 1} + \boldsymbol{\varepsilon}_{n \times 1}, \boldsymbol{\varepsilon} \sim (0, \sigma^2 \mathbf{I}_n), \boldsymbol{\varepsilon} \perp \mathbf{X}$   
假设  $\mathbf{X}$  列满秩, 最小二乘法估计:  $\hat{\boldsymbol{\beta}} = \arg \min_{\boldsymbol{\beta}} \|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2$   
正则方程:  $\mathbf{X}'(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) = 0 \Rightarrow \hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y}$

• 拟合值:  $\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y} = \mathbf{H}\mathbf{Y}$

其中  $\mathbf{H} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}' = \mathbf{P}_X$ , 也称为帽子矩阵(hat matrix)

• 残差:  $\mathbf{e} = \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}} = (\mathbf{I}_n - \mathbf{H})\mathbf{Y}$

(1)  $\mathbf{X}'\mathbf{e} = 0, \mathbf{e} \perp \hat{\mathbf{Y}}$ ; (2)  $E(\mathbf{e} | \mathbf{X}) = 0, \text{var}(\mathbf{e} | \mathbf{X}) = (\mathbf{I}_n - \mathbf{H})\sigma^2$

• 残差平方和:  $RSS = \|\mathbf{e}\|^2 = \|\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}\|^2 = \mathbf{Y}'(\mathbf{I}_n - \mathbf{H})\mathbf{Y}$

• 取  $\hat{\sigma}^2 = \frac{1}{n-p} \sum e_i^2 = \frac{1}{n-p} \|\mathbf{e}\|^2 = \frac{RSS}{n-p}$  称为  $\sigma^2$  的 LS 估计

2

总结 最小二乘法: 从模型方程到拟合方程

模型方程	$Y = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \boldsymbol{\varepsilon} \sim (0, \sigma^2 \mathbf{I}_n), \boldsymbol{\varepsilon} \perp \mathbf{X}$
最小二乘法	$\min_{\boldsymbol{\beta}} \sum (y_i - \mathbf{x}_i' \boldsymbol{\beta})^2 = \min_{\boldsymbol{\beta}} \ \mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\ ^2$
正则方程	$\mathbf{X}'(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = 0$
LS 估计	$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y}$
拟合值 / 投影	$\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y} = \mathbf{P}_X \mathbf{Y}$
残差	$\mathbf{e} = \mathbf{Y} - \hat{\mathbf{Y}} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}} = (\mathbf{I}_n - \mathbf{H})\mathbf{Y}$
残差平方和	$RSS = \ \mathbf{e}\ ^2 = \mathbf{Y}'(\mathbf{I}_n - \mathbf{H})\mathbf{Y}$
误差方差估计	$\hat{\sigma}^2 = \frac{RSS}{n-p}$
拟合方程 / 正交分解	$Y = \mathbf{X}\hat{\boldsymbol{\beta}} + \mathbf{e}, \mathbf{e} \sim (0, \sigma^2(\mathbf{I}_n - \mathbf{H})), \mathbf{e} \perp \mathbf{X}$

3

利用最小二乘法求解LS估计

记设计阵  $\mathbf{X} = (\mathbf{x}_0 \equiv \mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_{p-1})$ , 即  $\mathbf{X}$  各列记为  $\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_{p-1}$

模型:  $Y = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} = \mathbf{x}_0\beta_0 + \dots + \mathbf{x}_{p-1}\beta_{p-1} + \boldsymbol{\varepsilon}, \boldsymbol{\varepsilon} \sim (0, \sigma^2 \mathbf{I}_n), \boldsymbol{\varepsilon} \perp \mathbf{X}$

注意到  $\mathbf{X}\boldsymbol{\beta} = \mathbf{x}_0\beta_0 + \dots + \mathbf{x}_{p-1}\beta_{p-1}$  为  $\mathbf{X}$  各列向量的线性组合,

最小二乘  $\min_{\boldsymbol{\beta}} \|\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}\|^2 \Leftrightarrow \min_{\mathbf{u} \in L(\mathbf{X})} \|\mathbf{Y} - \mathbf{u}\|^2$

定理8(第七讲): 记  $\hat{\mathbf{Y}} = \mathbf{P}_X \mathbf{Y} \in L(\mathbf{X})$  为  $\mathbf{Y}$  在  $L(\mathbf{X})$  上的投影,

则  $\|\mathbf{Y} - \hat{\mathbf{Y}}\|^2 = \min_{\mathbf{u} \in L(\mathbf{X})} \|\mathbf{Y} - \mathbf{u}\|^2$

4

$\hat{Y}$ 作为最优的 $X$ 各列的线性组合,  $\hat{Y} = X \hat{\beta}$ ,

其组合系数 $\hat{\beta}$ 即为LS解,事实上:

$$\text{由 } \hat{Y} = P_X Y = X(X'X)^{-1}X'Y = X \{ \underline{(X'X)^{-1}X'Y} \},$$

$$\text{所以 } \beta \text{ 的最小二乘估计 } \hat{\beta} = \underline{(X'X)^{-1}X'Y}$$

注: 从解方程的观点来看:

$$Y = X\beta \text{ 一般无解 (因为 } n \geq p, \text{ 一般 } Y \notin L(X)),$$

但

$$\hat{Y} = X\beta \text{ 有解 (因为 } \hat{Y} \in L(X)),$$


而且当 $X$ 列满秩时解唯一

(若  $\hat{Y} = X\beta = X\gamma$ , 则  $X(\beta - \gamma) = 0$ , 因为 $X$ 列满秩, 则  $\beta = \gamma$ )

5

拟合值向量  $\hat{Y} = X\hat{\beta} = P_X Y$  即投影

残差向量  $e = Y - \hat{Y} = (I - P_X)Y$  为  $Y$  在  $L(X)^\perp$  上的投影,



$$\text{正交分解: } Y = \hat{Y} \oplus e, \quad e \perp \hat{Y}$$

6

## 拟合优度: 复相关系数平方 $R^2$

$$Y = \hat{Y} \oplus e \quad (\text{正交分解, } e \perp \hat{Y})$$

因为 $X$ 的第一列为 $\mathbf{1}$

$$\Rightarrow Y - \mathbf{1}\bar{Y} = (\hat{Y} - \mathbf{1}\bar{Y}) \oplus e \quad (e \perp \hat{Y} - \mathbf{1}\bar{Y})$$

$$\Rightarrow \|Y - \mathbf{1}\bar{Y}\|^2 = \|\hat{Y} - \mathbf{1}\bar{Y}\|^2 + \|e\|^2$$

$$\text{记为 } SS_Y = SS_{\hat{Y}} + RSS$$

$$\text{或 } SS_{\text{总}} = SS_{\text{回}} + RSS$$

$$\text{定义: 复相关系数平方 } R^2 = \frac{SS_{\hat{Y}}}{SS_Y} = \frac{\|\hat{Y} - \mathbf{1}\bar{Y}\|^2}{\|Y - \mathbf{1}\bar{Y}\|^2}$$

$$\text{Adjusted R-squared: } \bar{R}^2 = 1 - (1 - R^2) \frac{n-1}{n-p}$$

7

命题. 复相关平方为响应向量 $Y$ 与拟合值向量 $\hat{Y}$ 的相关系数的平方, 即  $R^2 = [r_{Y\hat{Y}}]^2$

$$\text{证明: } [r_{Y\hat{Y}}]^2 = \frac{\left( \sum (Y_i - \bar{Y})(\hat{Y}_i - \bar{Y}) \right)^2}{\sum (Y_i - \bar{Y})^2 \sum (\hat{Y}_i - \bar{Y})^2} = \frac{\left( (Y - \mathbf{1}\bar{Y})'(\hat{Y} - \mathbf{1}\bar{Y}) \right)^2}{\|Y - \mathbf{1}\bar{Y}\|^2 \|\hat{Y} - \mathbf{1}\bar{Y}\|^2}.$$

因为  $(\hat{Y} - \mathbf{1}\bar{Y}) \in L(X)$ , 所以  $e'(\hat{Y} - \mathbf{1}\bar{Y}) = 0$ ,

$$(Y - \mathbf{1}\bar{Y})'(\hat{Y} - \mathbf{1}\bar{Y}) = (\hat{Y} + e - \mathbf{1}\bar{Y})'(\hat{Y} - \mathbf{1}\bar{Y})$$

$$= (\hat{Y} - \mathbf{1}\bar{Y})'(\hat{Y} - \mathbf{1}\bar{Y}) = \|\hat{Y} - \mathbf{1}\bar{Y}\|^2$$

$$\Rightarrow [r_{Y\hat{Y}}]^2 = \frac{\|\hat{Y} - \bar{Y}\mathbf{1}\|^2}{\|Y - \bar{Y}\mathbf{1}\|^2} = R^2$$

8

## 部分回归系数估计的表达

为了求解LS估计, 可先投影得到投影 $\hat{Y}$ , 其 $X$ 后面的系数(唯一确定)即是 $\hat{\beta}$ . 由于 $\hat{Y} = X\hat{\beta} = \sum_{j=0}^{p-1} x_j \hat{\beta}_j$ ,  $x_j$ ( $X$ 的第 $j$ 列)的系数即为 $\hat{\beta}_j$

命题1: 划分 $X = (X_1, X_2)$ ,  $\beta = \begin{pmatrix} \beta_{(1)} \\ \beta_{(2)} \end{pmatrix}$   $(p-q) \times 1$ , 设 $\mathbf{1}$ 在 $X_1$ 中。

$$Y = X\beta + \varepsilon = X_1\beta_{(1)} + X_2\beta_{(2)} + \varepsilon,$$

令 $X_2^\perp = X_2 - P_{X_1}X_2$ , 则 $\beta_{(2)}$ 的LS估计为 $\hat{\beta}_{(2)} = (X_2^{\perp'}X_2^\perp)^{-1}X_2^{\perp'}Y$

且  $\text{var}(\hat{\beta}_{(2)} | X) = \sigma^2 (X_2^{\perp'}X_2^\perp)^{-1}$

证明1: 利用分块矩阵求逆公式(上节课)。

9

证明2:

令 $X_2^\perp = X_2 - P_{X_1}X_2$ 是 $X_2$ 的正交化, 则  $\hat{Y} = P_X Y = P_{X_1} Y + P_{X_2^\perp} Y$ , 其中 $X_2$ 的系数, 即为 $\hat{\beta}_{(2)}$ .

$$\begin{aligned} \text{由 } \hat{Y} &= P_{X_1} Y + P_{X_2^\perp} Y = X_1 (X_1' X_1)^{-1} X_1' Y + X_2^\perp (X_2^{\perp'} X_2^\perp)^{-1} X_2^{\perp'} Y \\ &= X_1 (X_1' X_1)^{-1} X_1' Y + \{X_2 - X_1 (X_1' X_1)^{-1} X_1' X_2\} (X_2^{\perp'} X_2^\perp)^{-1} X_2^{\perp'} Y \\ &= X_1 \{ (X_1' X_1)^{-1} X_1' Y - (X_1' X_1)^{-1} X_1' X_2 (X_2^{\perp'} X_2^\perp)^{-1} X_2^{\perp'} Y \} + X_2 (X_2^{\perp'} X_2^\perp)^{-1} X_2^{\perp'} Y \\ &= X_1 \hat{\beta}_{(1)} + X_2 \hat{\beta}_{(2)}, \text{ 所以 } \hat{\beta}_{(2)} = (X_2^{\perp'} X_2^\perp)^{-1} X_2^{\perp'} Y \end{aligned}$$

10

证明3: 为了求解 $\beta_{(2)}$ 的LS估计, 分解 $X_2 = X_2^\perp + P_{X_1}X_2$ , 改写模型:

$$Y = X_1\beta_{(1)} + X_2\beta_{(2)} + \varepsilon = X_1\beta_{(1)} + (X_2^\perp + P_{X_1}X_2)\beta_{(2)} + \varepsilon$$

$$= X_1[\beta_{(1)} + (X_1' X_1)^{-1} X_1' X_2 \beta_{(2)}] + X_2^\perp \beta_{(2)} + \varepsilon$$

令 $\beta_{(1)}^* = \beta_{(1)} + (X_1' X_1)^{-1} X_1' X_2 \beta_{(2)}$ , 模型等价地表示为:

$$Y = X_1\beta_{(1)}^* + X_2^\perp \beta_{(2)} + \varepsilon = X^* \beta^* + \varepsilon$$

(1) 由 $\hat{Y} = P_X Y = P_{X_1} Y + P_{X_2^\perp} Y = X_1 (X_1' X_1)^{-1} X_1' Y + X_2^\perp (X_2^{\perp'} X_2^\perp)^{-1} X_2^{\perp'} Y$

$X_2^\perp$ 后面的系数  $(X_2^{\perp'} X_2^\perp)^{-1} X_2^{\perp'} Y$  即为 $\hat{\beta}_{(2)}$ , 或更简单地

(2) 由于 $X^* X^*$ 是对角分块矩阵

$$\begin{pmatrix} \hat{\beta}_{(1)}^* \\ \hat{\beta}_{(2)} \end{pmatrix} = (X^* X^*)^{-1} X^{*'} Y = \begin{pmatrix} X_1' X_1 & 0 \\ 0 & X_2^{\perp'} X_2^\perp \end{pmatrix}^{-1} \begin{pmatrix} X_1' Y \\ X_2^{\perp'} Y \end{pmatrix} = \begin{pmatrix} (X_1' X_1)^{-1} X_1' Y \\ (X_2^{\perp'} X_2^\perp)^{-1} X_2^{\perp'} Y \end{pmatrix}$$

11

注1:  $P_{X_2^\perp} Y = X_2^\perp \hat{\beta}_{(2)}$ 可看作是 $X_2$ 对 $\hat{Y}$ 的单独的贡献。

比如检验 $H_0: \beta_{(2)} = 0$ , 将主要依据  $\|X_2^\perp \hat{\beta}_{(2)}\|^2$  的大小,

$F$ 检验  $\propto \|X_2^\perp \hat{\beta}_{(2)}\|^2 / \text{RSS}$

注2: 设 $\mathbf{1}$ 在 $X_1$ 中,  $Y - \mathbf{1}\bar{Y} = (\hat{Y} - \mathbf{1}\bar{Y}) \oplus \mathbf{e} = (X_1 \hat{\beta}_{(1)}^* - \mathbf{1}\bar{Y}) \oplus X_2^\perp \hat{\beta}_{(2)} \oplus \mathbf{e}$

$$\|Y - \mathbf{1}\bar{Y}\|^2 = \|\hat{Y} - \mathbf{1}\bar{Y}\|^2 + \text{RSS} = \|X_1 \hat{\beta}_{(1)}^* - \mathbf{1}\bar{Y}\|^2 + \|X_2^\perp \hat{\beta}_{(2)}\|^2 + \text{RSS}$$

注3: 若 $X_1' X_2 = 0$  则 $\hat{\beta}_{(1)} = (X_1' X_1)^{-1} X_1' Y$ ,  $\hat{\beta}_{(2)} = (X_2^{\perp'} X_2^\perp)^{-1} X_2^{\perp'} Y$

若 $X = (x_0, x_1, \dots, x_{p-1})$ 的各列正交, 则  $\hat{\beta}_k = (x_k' x_k)^{-1} x_k' Y$

12

