

第十七讲. LS估计的性质及F检验

1

最小二乘估计的性质

性质1. 无偏性: $E(\hat{\beta} | X) = \beta$, 方差: $\text{var}(\hat{\beta} | X) = \sigma^2 (X'X)^{-1}$

$$\begin{aligned} \text{证明: } E(\hat{\beta} | X) &= E\{(X'X)^{-1} X'Y | X\} \\ &= (X'X)^{-1} X'E(Y | X) = (X'X)^{-1} X'E\{X\beta + \varepsilon | X\} \\ &= \beta + (X'X)^{-1} X'E\{\varepsilon | X\} \end{aligned}$$

因为 ε 与 X 独立, 所以 $E\{\varepsilon | X\} = E\{\varepsilon\} = 0$, 所以 $E(\hat{\beta} | X) = \beta$

$$\text{var}(\hat{\beta} | X) = (X'X)^{-1} X' \text{var}(\varepsilon | X) X (X'X)^{-1} = \sigma^2 (X'X)^{-1}$$

注1: 分量 $\hat{\beta}_k$ 是 β_k 的无偏估计, 线性组合 $c'\hat{\beta}$ 是 $c'\beta$ 的无偏估计

2

性质2(相合性及渐近正态性). 设 (\tilde{x}_i, y_i) iid满足线性模型

$$y_i = \tilde{x}_i' \beta + \varepsilon_i, \varepsilon_i \sim (0, \sigma^2) \text{ 与 } \tilde{x}_i \text{ 独立 (不假设 } \varepsilon_i \text{ 正态)}.$$

设 $\hat{\beta}$ 为LS估计, 则当 $n \rightarrow \infty$ 时,

(1) 相合性: $\hat{\beta} \xrightarrow{p} \beta$;

(2) 渐近正态性: $\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(0, \sigma^2 M^{-1})$, $M = E(\tilde{x}_i \tilde{x}_i')$

证明:(1) 由大数定律 $\frac{1}{n} \sum_{i=1}^n \tilde{x}_i \tilde{x}_i' \xrightarrow{p} M$, $\frac{1}{n} \sum_{i=1}^n \tilde{x}_i \varepsilon_i' \xrightarrow{p} E(\tilde{x}_i \varepsilon_i) = 0$

$$\text{故 } \hat{\beta} = (X'X)^{-1} X'Y = \beta + (X'X)^{-1} X'\varepsilon = \beta + \left(\frac{1}{n} \sum_{i=1}^n \tilde{x}_i \tilde{x}_i' \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n \tilde{x}_i \varepsilon_i \right) \xrightarrow{p} \beta$$

(2) 由中心极限定理 $\frac{1}{\sqrt{n}} \sum_{i=1}^n \tilde{x}_i \varepsilon_i \xrightarrow{d} N(0, \sigma^2 M)$, 而 $\frac{1}{n} \sum_{i=1}^n \tilde{x}_i \tilde{x}_i' \xrightarrow{p} M$

$$\text{故 } \sqrt{n}(\hat{\beta} - \beta) = \left(\frac{1}{n} \sum_{i=1}^n \tilde{x}_i \tilde{x}_i' \right)^{-1} \left(\frac{1}{\sqrt{n}} \sum_{i=1}^n \tilde{x}_i \varepsilon_i \right) \xrightarrow{d} N(0, \sigma^2 M^{-1})$$

3

性质 3. $\hat{\sigma}^2 = \frac{RSS}{n-p}$, 则 $E(\hat{\sigma}^2 | X) = \sigma^2$

$$\text{证明: } \hat{\sigma}^2 = \frac{1}{n-p} \|\mathbf{e}\|^2 = \frac{1}{n-p} \mathbf{e}'\mathbf{e}.$$

因为 $\mathbf{e} = (I_n - H)Y = (I_n - H)(X\beta + \varepsilon) = (I_n - H)\varepsilon$,

且 $E(\varepsilon\varepsilon' | X) = \sigma^2 I_n$, 所以

$$\begin{aligned} E\{\mathbf{e}'\mathbf{e} | X\} &= E\{\varepsilon'(I_n - H)\varepsilon | X\} \\ &= E\{\text{tr}[(I_n - H)\varepsilon\varepsilon'] | X\} \\ &= \text{tr}[(I_n - H)E\{\varepsilon\varepsilon' | X\}] = \sigma^2 \text{tr}(I_n - H) = (n-p)\sigma^2 \end{aligned}$$

4

Gauss-Markov定理

定义(Loewner's 偏序): 对任何两个对称 $m \times m$ 矩阵 A, B , $A \geq B$ 定义为 $A - B \geq 0$ (非负定), 等价地对任何 x , $x'Ax \geq x'Bx$

性质: 若 $A \geq B$, 则对任何 $k \times m$ 矩阵 C , $CAC' \geq CBC'$

性质4 (Gauss - Markov定理). 最小二乘估计是最优无偏线性估计 (BLUE: best linear unbiased estimate), 即在所有 β 的线性无偏估计中, LS估计 $\hat{\beta} = (X'X)^{-1}X'Y$ 的方差最小 (Loewner偏序意义下)。

5

Gauss - Markov定理的证明:

设 $\tilde{\beta} = C_{p \times n}Y$ 是 β 的任一线性无偏估计, 所以

$$\beta = E(\tilde{\beta} | X) = E(CY | X) = CX\beta,$$

上式对任何 β 成立, 故 $CX = I_p$ 。

$\text{var}(\tilde{\beta} | X) = C \text{var}(Y | X)C' = \sigma^2 CC'$, 而 $\text{var}(\hat{\beta} | X) = \sigma^2 (X'X)^{-1}$ 所以需要证明因为 $CC' \geq (X'X)^{-1}$

因为 $I_n - H \geq 0$, 所以

$$CC' \geq CHC' = CX(X'X)^{-1}X'C' = (X'X)^{-1}$$

6

Gauss-Markov定理也表述为 (课本):

GM定理:

在所有 $c'\beta$ 的线性无偏估计中, LS估计 $c'\hat{\beta} = c'(X'X)^{-1}X'Y$ 的方差最小。

特别地, $\hat{\beta}_k$ 是 β_k 的BLUE, $\hat{\beta}_k - \hat{\beta}_j$ 是 $\beta_k - \beta_j$ 的BLUE, 等等。

GM定理:

假设 $A_{q \times p}$ ($q \leq p$) 行满秩, 记参数 $\theta_{q \times 1} = A\beta$, 则LS估计 $\hat{\theta} = A\hat{\beta}$ 是 $A\beta$ 的BLUE

特别地, 若 $A = (0, I_q)$, $A\beta = (0, I_q) \begin{pmatrix} \beta_{(1)} \\ \beta_{(2)} \end{pmatrix} = \beta_{(2)}$, 划分 $X = (X_1, X_2)$,

则 $\hat{\beta}_{(2)} = (X_2'X_2)^{-1}X_2'Y$ 是 $\beta_{(2)}$ 的BLUE

7

性质5. 如果误差服从正态分布 $\varepsilon_i \sim N(0, \sigma^2)$, 则

(1) β 的极大似然估计即LS估计;

(2) σ^2 的极大似然估计为 $\hat{\sigma}_{\text{mle}}^2 = \frac{1}{n} \text{RSS} = \frac{n-p}{n} \hat{\sigma}^2$,

(3) $\hat{\beta} | X \sim N(\beta, \sigma^2 (X'X)^{-1})$, $\frac{(n-p)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-p}^2$, 且两者独立。

证明: $\varepsilon \sim N(0, \sigma^2 I_n)$,

(3) $\hat{\beta} = (X'X)^{-1}X'Y = \beta + (X'X)^{-1}X'\varepsilon \sim N(\beta, \sigma^2 (X'X)^{-1})$

$$\mathbf{e} = (I_n - H)Y = (I_n - H)(X\beta + \varepsilon) = (I_n - H)\varepsilon,$$

$$\Rightarrow \frac{(n-p)\hat{\sigma}^2}{\sigma^2} = \frac{\|\mathbf{e}\|^2}{\sigma^2} = (\varepsilon/\sigma)'(I_n - H)(\varepsilon/\sigma) \sim \chi_{n-p}^2.$$


因为 $\underline{(X'X)^{-1}X'} \underline{(I_n - H)} = 0$, 所以 $\hat{\beta}$ 与 $\hat{\sigma}^2$ 独立

8

F 检验

F-分布也叫做Snedecor's F-分布或者Fisher-Snedecor分布，其定义为两个独立平均卡方随机变量之比的分布：

$$F = \frac{\chi_m^2 / m}{\chi_n^2 / n} \sim F_{m,n}$$



为了表示对Fisher的敬意，G.W. Snedecor 将其称作F-分布。



9

部分回归系数的显著性检验

全模型: $Y_{n \times 1} = X_{n \times p} \beta_{p \times 1} + \varepsilon_{n \times 1} = X_1 \beta_{(1)} + X_2 \beta_{(2)} + \varepsilon, \quad \varepsilon \sim N(\mathbf{0}, \sigma^2 I_n)$

其中 $X = (X_1, X_2)$, X_1 为 $n \times (p-q)$, 第一列为 $\mathbf{1}$. X_2 为 $n \times q$;

$\beta = \begin{pmatrix} \beta_{(1)} \\ \beta_{(2)} \end{pmatrix}$, $\beta_{(1)}$ 长度为 $p-q$ (含截距), $\beta_{(2)}$ 长度为 q .

原假设 $H_0: \beta_{(2)} = \mathbf{0}_{q \times 1}$,

子模型: $Y = X_1 \beta_{(1)} + \varepsilon, \quad \varepsilon \sim N(\mathbf{0}, \sigma^2 I_n)$ (原假设下的模型)

10

令 $X_2^\perp = X_2 - P_{X_1} X_2$, $\beta_{(1)}^* = \beta_{(1)} + (X_1' X_1)^{-1} X_1' X_2 \beta_{(2)}$

全模型: $Y = X_1 \beta_{(1)} + X_2 \beta_{(2)} + \varepsilon = X_1 \beta_{(1)}^* + X_2^\perp \beta_{(2)} + \varepsilon$

记 $\hat{Y} = P_X Y$ 为 Y 在 $V = L(X)$ 上的投影


记 $\hat{Y}_0 = P_{X_1} Y$ 为 Y 在 $V_0 = L(X_1) \subset V$ 上的投影

$\hat{Y} = P_X Y = P_{X_1} Y + P_{X_2^\perp} Y = X_1 \hat{\beta}_{(1)}^* + X_2^\perp \hat{\beta}_{(2)} \stackrel{\text{记为}}{=} \hat{Y}_0 + X_2^\perp \hat{\beta}_{(2)}$

如果原假设成立时 ($\beta_{(2)} = \mathbf{0}$), 则 $V = L(X)$ 和 $V_0 = L(X_1)$ 差异不大,

特别地, Y 在 V , V_0 上的投影之差 $\hat{Y} - \hat{Y}_0 = X_2^\perp \hat{\beta}_{(2)}$ 的模长差别不大。

11



考虑到刻度以及 q 的大小, F 检验取为

$$F = \frac{\|X_2^\perp \hat{\beta}_{(2)}\|^2 / q}{\hat{\sigma}^2} = \frac{\|\hat{Y} - \hat{Y}_0\|^2 / q}{\|Y - \hat{Y}\|^2 / (n-p)} = \frac{n-p}{q} \text{ctg}(\omega)^2$$

12

定理：原假设下 $F \sim F_{q,n-p}$

证明1: 利用 $F = \frac{\|X_2^\perp \hat{\beta}_{(2)}\|^2}{q\hat{\sigma}^2}$ 。

由 $\hat{\beta} \sim N(\beta, \sigma^2(X'X)^{-1})$, 知 $\hat{\beta}_{(2)} \sim N(\beta_{(2)}, \sigma^2(X_2^\perp X_2^\perp)^{-1})$

H_0 成立时, $\beta_{(2)} = 0$, 所以 $A = \|X_2^\perp \hat{\beta}_{(2)}\|^2 = \hat{\beta}_{(2)}' X_2^\perp X_2^\perp \hat{\beta}_{(2)} \sim \sigma^2 \chi_q^2$

另外, $B = (n-p)\hat{\sigma}^2 \sim \sigma^2 \chi_{n-p}^2$, 且与 $\hat{\beta}$ 独立,

所以 $\frac{A/q}{B/(n-p)} = \frac{\|X_2^\perp \hat{\beta}_{(2)}\|^2}{q\hat{\sigma}^2} = F \sim F_{q,n-p}$

13

证明2: 利用 $F = \frac{n-p}{q} \times \frac{\|\hat{Y} - \hat{Y}_0\|^2}{\|Y - \hat{Y}\|^2}$ 。

(1) 因为 $\epsilon \sim N(0, \sigma^2 I_n)$, 以及 $Y - \hat{Y} = (I_n - P_X)\epsilon$

$$\Rightarrow \frac{(n-p)\hat{\sigma}^2}{\sigma^2} = \frac{\|Y - \hat{Y}\|^2}{\sigma^2} \sim \chi_{n-p}^2 \text{ (不论 } H_0 \text{ 成立与否)}.$$

(2) 原假设下 $Y = X_1 \beta_{(1)} + \epsilon$, $\epsilon \sim N(0, \sigma^2 I_n)$

所以 $\hat{Y} - \hat{Y}_0 = P_X Y - P_{X_1} Y = P_{X_2^\perp} Y = P_{X_2^\perp} (X_1 \beta_{(1)} + \epsilon) = P_{X_2^\perp} \epsilon$

$$\Rightarrow \frac{\|\hat{Y} - \hat{Y}_0\|^2}{\sigma^2} \sim \chi_q^2$$


(3) 因为 $(I_n - P_X)P_{X_2^\perp} = 0$, 所以 $\|\hat{Y} - \hat{Y}_0\|^2$ 与 $\|Y - \hat{Y}\|^2$ 独立,

$$\Rightarrow F = \frac{\|\hat{Y} - \hat{Y}_0\|^2 / q}{\|Y - \hat{Y}\|^2 / (n-p)} \sim F_{q,n-p}$$

14

F的其它表达

$$\begin{aligned} F &= \frac{\|X_2^\perp \hat{\beta}_{(2)}\|^2 / q}{\hat{\sigma}^2} \\ &= \frac{\|\hat{Y} - \hat{Y}_0\|^2 / q}{\|Y - \hat{Y}\|^2 / (n-p)} \\ &= \frac{n-p}{q} \cot^2(\omega) \end{aligned}$$



$$F = \frac{n-p}{q} \times \frac{RSS_0 - RSS}{RSS}$$

这是因为 $\|\hat{Y} - \hat{Y}_0\|^2 = \|e_0 - e\|^2 = \|e_0\|^2 - \|e\|^2 = RSS_0 - RSS$
其中 $RSS = \|e\|^2$, $RSS_0 = \|e_0\|^2$ 为全, 子模型下的残差平方和

$$F = \frac{n-p}{q} \times \frac{R^2 - R_0^2}{1 - R^2}$$

这是因为 $\|\hat{Y} - \hat{Y}_0\|^2 = \|\hat{Y} - \bar{Y}\|^2 - \|\hat{Y}_0 - \bar{Y}\|^2$ 及
 $R^2 = \|\hat{Y} - \bar{Y}\|^2 / SS_{\text{总}}$, $R_0^2 = \|\hat{Y}_0 - \bar{Y}\|^2 / SS_{\text{总}}$

15

方差分析

$$F = \frac{n-p}{q} \times \frac{RSS_0 - RSS}{RSS}$$

上述形式表明F-检验可看作是是比较全模型和子模型的拟合程度。比较残差平方和也称作ANOVA (ANalysis Of Variance, 方差分析)

$$\begin{aligned} SS_{\text{总}} &= \|Y - \bar{Y}\|^2 \\ &= \|\hat{Y} - \bar{Y}\|^2 + RSS \\ &= \|\hat{Y}_0 - \bar{Y}\|^2 + \|\hat{Y} - \hat{Y}_0\|^2 + RSS \\ &= \|\hat{Y}_0 - \bar{Y}\|^2 + (RSS_0 - RSS) + RSS \end{aligned}$$

X1解释的部分 **X1**不能解释,但**x2**能解释的部分 **X1,x2**都不能解释的部分

> anova (sub.model, full.model)

$Y \sim X1$

$Y \sim X1 + X2$

16

特例1. 单个回归系数的t-检验 $H_0: \beta_k = 0$

$$F = \frac{\| \mathbf{x}_k^\perp \hat{\beta}_k \|^2}{\hat{\sigma}^2} = \frac{\hat{\beta}_k^2}{\hat{\sigma}^2 / \| \mathbf{x}_k^\perp \|^2} \sim_{H_0} F_{1, n-p}$$

$$t = \pm \sqrt{F} = \frac{\hat{\beta}_k}{\hat{\sigma} / \| \mathbf{x}_k^\perp \|} \sim_{H_0} t_{n-p}$$

这可由 $\hat{\beta}_k \sim N(\beta_k, \sigma^2 / \| \mathbf{x}_k^\perp \|^2)$ 直接得到。

17

特例2. 回归方程的显著性检验

$$Y = \mathbf{1}\beta_0 + Z\gamma + \varepsilon, \beta_0 \text{ 是截距}$$

$$H_0: \gamma = (\beta_1, \dots, \beta_{p-1})' = 0$$


记 $Z^\perp = Z - P_1 Z = Z - \mathbf{1}\bar{x}'$ 为自变量的中心化矩阵。

回归方程显著性的 F 检验:

$$F = \frac{n-p}{p-1} \times \frac{\| \hat{Y} - \hat{Y}_0 \|^2}{\| Y - \hat{Y} \|^2} = \frac{\| Z^\perp \hat{\gamma} \|^2}{(p-1)\hat{\sigma}^2} \sim_{H_0} F_{p-1, n-p}$$

其中 $\hat{Y}_0 = \mathbf{1}\bar{y}$, 所以 $F = \frac{n-p}{p-1} \times \frac{R^2}{1-R^2}$

18



$$\cos^2 \omega = \frac{\| \hat{Y} - \mathbf{1}\bar{y} \|^2}{\| Y - \mathbf{1}\bar{y} \|^2} = R^2$$

$$F = \frac{n-p}{p-1} \times \frac{\| \hat{Y} - \hat{Y}_0 \|^2}{\| Y - \hat{Y} \|^2} = \frac{n-p}{p-1} \times \frac{R^2}{1-R^2} = \frac{n-p}{p-1} \times (\cot \omega)^2$$

19

$$\text{Salary} = \beta_0 + \beta_1 \text{Sex} + \beta_2 \text{Rank} + \beta_3 \text{Year} + \varepsilon$$

Call:
lm(formula = Salary ~ Sex + Rank + Year, data = salary)

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11011.76	966.95	11.388	3.03e-15 ***
Sex	603.77	811.20	0.744	0.46
Rank	4747.18	452.58	10.489	5.18e-14 ***
Year	393.86	74.53	5.285	3.04e-06 ***

Residual standard error: 2398 on 48 degrees of freedom
Multiple R-squared: 0.8454, Adjusted R-squared: 0.8358
F-statistic: 87.51 on 3 and 48 DF, p-value: < 2.2e-16

回归方程的显著性检验 \sqrt{F} 单个回归系数的t检验

20

$$\text{Salary} = \beta_0 + \beta_1 \text{Sex} + \beta_2 \text{Rank} + \beta_3 \text{Year} + \varepsilon$$

$$H_0 : \beta_2 = \beta_3 = 0$$

```
> m2 = lm(Salary~Sex+Rank+Year, data=salary)
```

```
> m1 = lm(Salary~Sex, data=salary)
```

```
> anova(m1, m2)
```

Analysis of Variance Table

Model 1: Salary ~ Sex

Model 2: Salary ~ Sex + Rank + Year

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	50	1671623638				
2	48	276016717	2	1395606921	121.35	< 2.2e-16 ***

$$F = \frac{n-p}{q} \times \frac{RSS_0 - RSS}{RSS} = \frac{52-4}{2} \times \frac{1671623638 - 276016717}{276016717} = 121.35$$