

## 第二十三讲. 广义最小二乘(GLS)

1

如果回归诊断发现线性回归模型假设不成立:


(1) 误差方差(heteroscedasticity):

解决方案: 数据变换, GLS(广义最小二乘), GLM(广义线性模型)

(2) 均值非线性(非正态)

解决方案: 数据变换, 非线性回归, GLM

2



$Y = X\beta + \varepsilon$ ,  $\varepsilon \sim$  误差方差矩阵  $G$ .

(1) 如果  $G$  完全未知, 仍可应用 LS 方法, LS 估计无偏但方差过大。

(2) 如果  $G$  完全已知, 则应用 GLS 方法;

(3) 如果  $G$  结构已知, 仅含少数未知参数, 应用 IRLS 方法。

比如上图  $G = \text{diag}(\sigma_1^2, \dots, \sigma_1^2, \sigma_2^2, \dots, \sigma_2^2)$

3

### GLS (Generalized LS): 误差方差不等但已知情况

**OLS**: 通常的(ordinary)最小二乘(等方差情形)

**GLS**: 广义最小二乘法 (Generalized Least Squares), 也称做加权 LS, 应用于异方差 heteroscedasticity 或各次观察不独立情形。

例1. 若  $y_1, \dots, y_n$  独立,  $y_i \sim N(\mu, \sigma_i^2)$ ,  $\mu$  未知。假设  $\sigma_i^2$  已知, 则极大似然估计

$$\max L \Leftrightarrow \min \sum \frac{(y_i - \mu)^2}{\sigma_i^2}, \text{ 解为 } \hat{\mu}_{\text{GLS}} = \frac{\sum y_i / \sigma_i^2}{\sum 1 / \sigma_i^2} \text{ 称为 GLS}$$

$$\text{但 } \hat{\mu}_{\text{OLS}} = \bar{y} = \text{argmin} \sum (y_i - \mu)^2, \text{ 称为 OLS}$$

$$\text{两者都是无偏估计, 但: } \text{var}(\hat{\mu}_{\text{GLS}}) = \frac{1}{\sum 1 / \sigma_i^2} \leq \frac{\sum \sigma_i^2}{n^2} = \text{var}(\hat{\mu}_{\text{OLS}})$$

4

模型:  $Y = X\beta + \varepsilon, E(\varepsilon | X) = 0, \text{var}(\varepsilon | X) = G \geq 0$  ( $G$ 已知),  $\varepsilon \perp X$

GLS方法:

首先  $Y = X\beta + \varepsilon$  两边同乘  $G^{-1/2}$ :

$$Y^* = G^{-1/2}Y = G^{-1/2}X\beta + G^{-1/2}\varepsilon = X^*\beta + \varepsilon^* \quad (*)$$

误差项  $\varepsilon^* = G^{-1/2}\varepsilon$  满足:  $E(\varepsilon^* | X) = 0, \text{var}(\varepsilon^* | X) = I_n$

对模型(\*)应用OLS方法,即

$$\min(Y^* - X^*\beta)'(Y^* - X^*\beta) = \min(Y - X\beta)'G^{-1}(Y - X\beta)$$

$$\begin{aligned} \text{得 } \hat{\beta}_{\text{GLS}} &= (X^{*'}X^*)^{-1}X^{*'}Y^* = [(G^{-1/2}X)'(G^{-1/2}X)]^{-1}(G^{-1/2}X)'G^{-1/2}Y \\ &= (X'G^{-1}X)^{-1}X'G^{-1}Y \end{aligned}$$

5

容易验证:

$$(1) E(\hat{\beta}_{\text{GLS}} | X) = \beta,$$

$$(2) \text{var}(\hat{\beta}_{\text{GLS}} | X) = (X'G^{-1}X)^{-1}$$

另外一种做法是不管  $G$  是否具有形式  $G = \sigma^2 I_n$ ,

直接应用通常的最小二乘法(OLS):

$$\text{argmin} \|Y - X\beta\|^2 \Rightarrow \hat{\beta}_{\text{OLS}} = (X'X)^{-1}X'Y$$

$$(1) E(\hat{\beta}_{\text{OLS}} | X) = \beta, \text{ 无偏。}$$

$$\begin{aligned} (2) \text{var}(\hat{\beta}_{\text{OLS}} | X) &= (X'X)^{-1}X'\text{var}(Y | X)X'(X'X)^{-1} \\ &= (X'X)^{-1}X'GX(X'X)^{-1} \end{aligned}$$

6

模型(\*)满足Gauss - Markov假设, 由GM定理知其OLS

估计  $\hat{\beta}_{\text{GLS}}$  是BLUE, 即

$$\text{var}(\hat{\beta}_{\text{OLS}} | X) \geq \text{var}(\hat{\beta}_{\text{GLS}} | X) \Leftrightarrow$$

$$(X'X)^{-1}X'GX(X'X)^{-1} \geq (X'G^{-1}X)^{-1}$$

直接证明该矩阵不等式:

只需证  $(X'X)(X'G^{-1}X)^{-1}(X'X) \leq X'GX$

左端 =  $X'G^{1/2} \underline{G^{-1/2}X(X'G^{-1}X)^{-1}X'G^{-1/2}G^{1/2}}X \leq X'G^{1/2}G^{1/2}X = X'GX$

其中下划线部分(投影阵)  $G^{-1/2}X(X'G^{-1}X)^{-1}X'G^{-1/2} \leq I_n$ 。

综上, 线性回归模型的等方差假设不是本质的, 即使不满足等方差假设, OLS估计也是无偏的, 但OLS估计效率偏低。

7

## G未知情形: 迭代加权最小二乘方法 (Iteratively reweighted least squares, IRLS)

$G$ 通常是未知的。

如果  $G$  完全未知, 因其含有  $n(n+1)/2$  个参数, 不可估计。

所以需要根据具体问题假设  $G$  具有某种简单结构, 即参数化。

一种最简单的方差结构 假设是  $G = \sigma^2 I_n$  (误差独立同分布),

此时  $\hat{\beta}_{\text{GLS}} = (X'G^{-1}X)^{-1}X'G^{-1}Y = (X'(\sigma^2 I_n)^{-1}X)^{-1}X'(\sigma^2 I_n)^{-1}Y$

$= (X'X)^{-1}X'Y = \hat{\beta}_{\text{OLS}}$  不依赖于未知参数  $\sigma^2$ 。

此时GLS即OLS, 即不需要估计  $\sigma^2$  也能估计  $\beta$ 。

8

对于其它形式的G,  $\hat{\beta}_{GLS}$  涉及G, 所以必须同时估计 $\beta$ 和G。

同时估计 $\beta$ 和G, 计算上不再像OLS, GLS那么简单。  
一种策略是分步估计: 即先估计G, 再计算GLS估计。

但估计G必定用到残差, 而残差与 $\beta$ 的估计有关..

**IRLS方法是一个迭代算法:**

给定初始G,


由GLS方法得到回归系数估计, 并得到残差,  
基于残差更新G的估计,  
循环。

9

例1. 对于下图所示的独立样本情形, 异方差 (heteroscedasticity) 模型

$$Y = X\beta + \varepsilon, \varepsilon \sim (0, G), G = \text{diag}(\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2)$$

假设  $\sigma_1^2 = \sigma_2^2 = \dots = \sigma_m^2 = \sigma^2$  (未知),  $\sigma_{m+1}^2 = \dots = \sigma_n^2 = \tau^2$  (未知)



GLS最小化:

$$\min_{\beta, \sigma^2, \tau^2} (Y - X\beta)' G^{-1} (Y - X\beta) = \min_{\beta, \sigma^2, \tau^2} \left( \sum_{i=1}^m \frac{(y_i - \tilde{x}_i \beta)^2}{\sigma^2} + \sum_{i=m+1}^n \frac{(y_i - \tilde{x}_i \beta)^2}{\tau^2} \right)$$

10

IRLS解法:

Step0.  $k = 0$ , 初始化  $G^{(0)} = \sigma^2 I_n$ .

Step1.  $k = k + 1$ ,

计算GLS估计  $\hat{\beta}^{(k)} = \hat{\beta}_{GLS} = (X' G^{(k-1)-1} X)^{-1} X' G^{(k-1)-1} Y$ ,

计算残差  $e = Y - X \hat{\beta}^{(k)}$

Step2.  $\hat{\sigma}^2 = \sum_{i=1}^m e_i^2 / (m - p)$ ,  $\hat{\tau}^2 = \sum_{i=m+1}^n e_i^2 / (n - m - p)$

$\Rightarrow G^{(k)} = \text{diag}(\hat{\sigma}^2, \dots, \hat{\sigma}^2, \hat{\tau}^2, \dots, \hat{\tau}^2)$

goto Step1, 重复至收敛。

11

例2. 假设模型  $Y = X\beta + \varepsilon, \varepsilon \sim (0, G)$ , 其中  $G = (\sigma^2 \rho^{|i-j|})_{1 \leq i, j \leq n}$

注意: 与以往不同, 这里我们各个观察之间是相依的

**IRLS :**

Step0. 由OLS方法得到  $\beta$  的无偏估计  $\hat{\beta}^{(0)}$ , 计算  $e = Y - X \hat{\beta}^{(0)}$

Step1.  $\hat{\sigma}^2 = \sum_{i=1}^n e_i^2 / (n - p)$ ,  $\hat{\rho} = \sum_{i=1}^{n-1} e_i e_{i+1} / \sum_{i=1}^n e_i^2$

$\Rightarrow G$  的估计  $\hat{G} = (\hat{\sigma}^2 \hat{\rho}^{|i-j|})_{1 \leq i, j \leq n}$

更新  $\beta$  的估计

$\hat{\beta}^{(1)} = (X' \hat{G}^{-1} X)^{-1} X' \hat{G}^{-1} Y$

Step2. 计算新的残差  $e = Y - X \hat{\beta}^{(1)}$

goto Step1, 重复直至收敛。

矩估计, 当然也可使用任何其它合理的估计

12

一般地,如果G未知(但具有简单结构), IRLS:

(0) 首先由OLS得到 $\beta$ 的一个无偏估计

$$\hat{\beta}^{(0)} = \hat{\beta}_{OLS}, \text{ 计算残差 } e = Y - X\hat{\beta}^{(0)}$$

(1) 考虑到G的特殊结构, 由残差得到G的估计 $\hat{G}^{(0)}$

(2) 由GLS方法更新 $\beta$ 的估计:

$$\hat{\beta}^{(1)} = (X' \hat{G}^{(0)-1} X)^{-1} X' \hat{G}^{(0)-1} Y$$

(3) 由此得到更新的残差 $e = Y - X\hat{\beta}^{(1)}$

goto (1), 重复至收敛

13

IRLS常用于如下优化问题:

$$\min \sum w_i(\beta, \theta) (y_i - x_i' \beta)^2$$

其中一般 $\theta$ 代表与方差有关的参数。比如稳健回归、广义线性模型(GLM)似然函数的最大化可以转化为上述优化问题。

IRLS:

(1) 初始化 $\beta^{(0)}$ : 比如 $\beta^{(0)} = \text{OLS估计}$ (视w为常数)

利用残差得到 $\theta$ 的估计 $\theta^{(0)}$ 【根据具体问题设计, 如例1,2红色下划线部分】

(2) 计算 $w_i(\beta^{(0)}, \theta^{(0)})$

$$\text{记 } G^{(0)} = \text{diag}(w_1(\beta^{(0)}, \theta^{(0)}), \dots, w_n(\beta^{(0)}, \theta^{(0)}))$$

(3) 更新 $\beta^{(1)} = \arg \min \sum w_i(\beta^{(0)}, \theta^{(0)}) (y_i - x_i \beta)^2 = (X' G^{(0)} X)^{-1} X' G^{(0)} Y$ ,

(4)  $\beta^{(0)} \leftarrow \beta^{(1)}$

goto (2)

14

例3 (线性模型的M-估计). 模型:  $Y = X\beta + \varepsilon, \varepsilon \sim (0, \sigma^2 I_n)$ ,

$$\min \sum \rho(y_i - x_i \beta)$$

$\rho(e) \geq 0$ 关于0对称,  $\rho(0) = 0$ .

$\rho(e) = |e|^p$  时:

$$\min \|Y - X\beta\|_p = \min \sum |y_i - x_i \beta|^p$$

称为最小 $L_p$ 方法,  $p=1$ 时称为最小一乘法(LAD: least absolute deviation).

对于最小 $L_p$ 方法, 改写目标函数:

$$\sum |y_i - x_i \beta|^p = \sum w_i(\beta) |y_i - x_i \beta|^2, \text{ 其中 } w_i(\beta) = |y_i - x_i \beta|^{p-2}$$

15

## Probit模型及广义线性模型

数据 $(y_i, x_i), i=1, \dots, n$ . 响应变量取值 0, 1, 如何建立回归模型?

### Probit 模型

假设均值函数 $p_i = P(y_i = 1 | x_i) = E(y_i | x_i)$ 具有如下结构

$$p_i = \Phi(x_i' \beta)$$

$\Phi$ 为 $N(0,1)$ 的累积分布函数。

解释: 假设有一个隐变量(latent)  $z_i$ , 连续, 但只能观察到

$$y_i = \begin{cases} 1, & z_i \geq 0 \\ 0, & z_i < 0 \end{cases}$$

假设 $z_i = x_i' \beta + \varepsilon_i, \varepsilon_i \text{ iid } \sim N(0,1)$ , 则

$$p_i = P(y_i = 1 | x_i) = P(x_i' \beta + \varepsilon_i \geq 0) = \Phi(x_i' \beta)$$

16

似然函数：

$$L(\alpha, \beta) = \prod p_i^{y_i} (1 - p_i)^{1-y_i} = \prod \Phi(\mathbf{x}_i' \beta)^{y_i} (1 - \Phi(\mathbf{x}_i' \beta))^{1-y_i}$$

$$\log L = \sum [y_i \log \Phi(\mathbf{x}_i' \beta) + (1 - y_i) \log (1 - \Phi(\mathbf{x}_i' \beta))]$$

极大化logL需要数值解法，比如 (1) Newton - Raphson 算法；

(2) Fisher scoring 算法；(3) IRLS；(4) EM 算法

其中Newton算法最快，但可能会因出现二阶导数矩阵不可逆而不收敛

Fisher scoring 算法将二阶导数矩阵换成Fisher信息阵（正定）

EM算法通常用于计算 latent variable或缺失数据模型的极大似然估计，

因为Probit模型是一个 latent variable 模型，所以我们介绍 EM算法

17

EM算法基于下述两步：

(M) 如果  $z_i$ 's能观察到，那么由  $z_i = \mathbf{x}_i' \beta + \varepsilon_i$ ，可得LS估计

$$\hat{\beta} = (\sum \mathbf{x}_i \mathbf{x}_i')^{-1} \sum \mathbf{x}_i z_i$$

(E) 如果  $\beta$  已知，那么我们可以预测  $z_i$ ：  $\hat{z}_i = E(z_i | \mathbf{x}_i, y_i, \beta)$ ，细节如下：

由  $z_i = \mathbf{x}_i' \beta + \varepsilon_i, \varepsilon_i \text{ iid} \sim N(0,1)$ ，得到  $z_i$  的条件分布：

$$P(z_i | \mathbf{x}_i, y_i, \beta) = P(y_i | z_i, \mathbf{x}_i, \beta) P(z_i | \mathbf{x}_i, \beta) / P(y_i | \mathbf{x}_i, \beta)$$

$$= y_i \phi(z_i - \mathbf{x}_i' \beta) / \Phi(\mathbf{x}_i' \beta)^{y_i} (1 - \Phi(\mathbf{x}_i' \beta))^{1-y_i}$$

$$= \begin{cases} \phi(z_i - \mathbf{x}_i' \beta) / \Phi(\mathbf{x}_i' \beta), & y_i = 1 \\ 0, & y_i = 0 \end{cases}$$

$$\Rightarrow \hat{z}_i = E(z_i | \mathbf{x}_i, y_i, \beta) = \begin{cases} \mathbf{x}_i' \beta + \phi(\mathbf{x}_i' \beta) / \Phi(\mathbf{x}_i' \beta), & y_i = 1 \\ \mathbf{x}_i' \beta - \phi(\mathbf{x}_i' \beta) / [1 - \Phi(\mathbf{x}_i' \beta)], & y_i = 0 \end{cases}$$

EM算法：选取初始值  $\beta_0$ ，预测  $z$ ，使用  $z$  求LS估计作为  $\beta$  的更新，重复 (E) - (M) - (E) - (M)....，至  $\beta$  收敛。

18

## Logistic回归模型

假设均值函数  $p_i = P(y_i = 1 | \mathbf{x}_i) = E(y_i | \mathbf{x}_i)$  具有如下结构

$$p_i = \frac{e^{\alpha + \mathbf{x}_i' \beta}}{1 + e^{\alpha + \mathbf{x}_i' \beta}}$$

注：

(1) Probit模型容易解释，在社会学、经济学、心理学中较为常见，但Logistic回归模型应用更为广泛；两个模型分析结果通常差异不大。

(2) logistic回归的似然函数：

$$L(\alpha, \beta) = \prod p_i^{y_i} (1 - p_i)^{1-y_i}, \text{ 其中 } p_i = \frac{e^{\alpha + \mathbf{x}_i' \beta}}{1 + e^{\alpha + \mathbf{x}_i' \beta}}$$

极大化似然函数求出参数估计。

19